



# 学术分享

## A Dual Weighting Label Assignment Scheme for Object Detection

(一种用于目标检测的双重加权标签分配方案--2022CVPR)

北京理工大学宇航学院

黄 晨

## ◆ DW的研究背景

①当前先进的单阶段检测器大多通过使用一组**预定义的锚框**来预测类别标签和回归偏移量以进行密集目标检测。作为检测器训练的基本单元，锚框需要被分配适当的类别和回归标签以监督训练过程。

②**标签分配 (LA)** 旨在为每个训练样本分配一个正 (pos) 和一个负 (neg) 损失权重，在目标检测中起着重要作用。

$$\mathcal{L}_{cls} = -w_{pos} \times \ln(s) - w_{neg} \times \ln(1 - s), \quad (1)$$

s: 预测分类得分

根据 $w_{pos}$ 和 $w_{neg}$ ，LA可分为hard LA和soft LA。

## ◆ DW的研究背景

Hard LA: 核心是找到适当分割边界, 将锚框分为正样本集和负样本集。

$$w_{\text{pos}}, w_{\text{neg}} \in \{0, 1\} \text{ and } w_{\text{pos}} + w_{\text{neg}} = 1$$



然而, 即使是正样本之间也不是同等重要的, 分类头部和回归头部之间具有更高一致性的锚框在训练期间应该具有更大的重要性。

## ◆ DW的研究背景

Soft LA: 核心是定义**软标签目标**，通过调制因子将其转换为损失权重。

① Generalized Focal Loss、Vari Focal Loss: IoU+调制因子

② 联合分类分数与回归分数计算样本权重

现有的方法主要集中于正加权函数的设计，而负权重简单地从正权重导出，形成耦合加权机制，如： $w_{neg} = 1 - w_{pos}$ 。

负权重函数与正权重函数高度相关，可能为具有不同属性的锚框分配几乎相同的（正，负）权重对，从而削弱训练的检测器的有效性。



	A	B	C	D
Score	0.95	0.7	0.6	0.3
IoU	0.95	0.4	0.6	0.6

	A	B	C	D	
$w_{pos}$	0.	0.04	0.	0.05	GFL
$w_{neg}$	0.	0.05	0.	0.04	
$w_{pos}$	0.9	0.16	0.36	0.36	VFL
$w_{neg}$	0.05	0.24	0.24	0.24	
$w_{pos}$	1.0	0.01	0.06	0.03	DW
$w_{neg}$	0.	0.55	0.31	0.08	

## ◆ DW的相关工作

### (1) 提出双加权样本分配方案

正权重  $w_{pos}$ : 置信度分数（分类头部）+ 回归分数（回归头部）动态组合。

负权重  $w_{neg}$ : 锚框是负样本的概率和锚框作为负样本的重要性。

### (2) 框细化操作

在回归头部设计可学习的轻量级预测模块，加入边界点的回归方式，为DW提供更准确的回归分数。



	A	B	C	D
Score	0.95	0.7	0.6	0.3
IoU	0.95	0.4	0.6	0.6

	A	B	C	D	
$w_{pos}$	0.	0.04	0.	0.05	GFL
$w_{neg}$	0.	0.05	0.	0.04	
$w_{pos}$	0.9	0.16	0.36	0.36	VFL
$w_{neg}$	0.05	0.24	0.24	0.24	
$w_{pos}$	1.0	0.01	0.06	0.03	DW
$w_{neg}$	0.	0.55	0.31	0.08	

## ◆ DW框架

## soft LA中的锚框损失

对于常规soft LA中的锚框损失：

$$\begin{aligned}\mathcal{L}_{cls} &= -w_{pos} \times \ln(s) - w_{neg} \times \ln(1 - s), \\ \mathcal{L}_{reg} &= w_{reg} \times \ell_{reg}(b, b'),\end{aligned}\quad (2)$$

$s$ : 预测分类得分

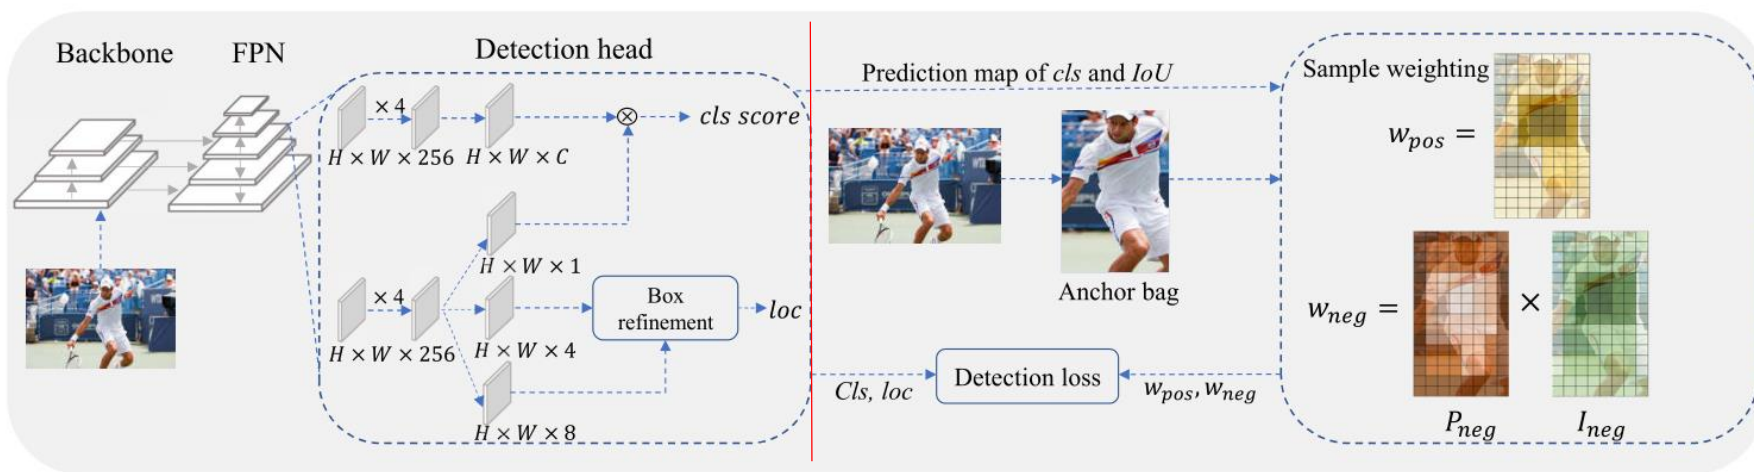
$\ell_{reg}$ : 回归损失     $b$ : 预测框位置  
 $b'$ : GT位置

Table 1. Comparison of different weighting functions.

Method	$w_{pos}$	$w_{neg}$	$t$
GFL [21]	$(s - t)^2 \times t$	$(s - t)^2 \times (1 - t)$	$IoU$
VFL [43]	$t \times t$	$t \times (1 - t)$	$IoU$
TOOD [9]	$(s - t)^2 \times t$	$(s - t)^2 \times (1 - t)$	$f(IoU, s)$
MuSu [11]	$(s - t)^2 \times t$	$s^2 \times (1 - t)^4$	$f(IoU, s)$
Ours (DW)	$f_{pos}(IoU, s)$	$P_{neg} \times I_{neg}$	-

## ◆ DW框架

## DW 框架pipeline



## ◆ DW框架

## 正权重函数

对于一个候选锚框来说，它被定义为正确的预测框需要满足两个条件：

1. 预测框与其最近的GT之间的IoU大于阈值  $\theta$ ；
2. 预测框的分类分数最高（排在预测框列表的最前面）。

→ 正权重  $w_{pos}$  应该与IoU和分类得分正相关：

$$w_{pos} \propto IoU \text{ and } w_{pos} \propto s$$

→ 定义一致性度量  $t$ ：

$\beta$ ：平衡  $s$  与  $IoU$

$$t = s \times IoU^\beta, \quad (3)$$

→ 正权重  $w_{pos}$ ：

$\mu$ ：超参数，控制不同锚框的相对差异

$$w_{pos} = e^{\mu t} \times t, \quad (4)$$



# ◆ DW框架

## 负权重函数

对于一致性较低的候选锚框，它们的重要性程度无法通过正权重 $w_{pos}$ 区分（可能具有相同的一致性程度 $t$ ）。



	A	B	C	D
Score	0.95	0.7	0.6	0.3
IoU	0.95	0.4	0.6	0.6

	A	B	C	D	
$w_{pos}$	0.	0.04	0.	0.05	GFL
$w_{neg}$	0.	0.05	0.	0.04	
$w_{pos}$	0.9	0.16	0.36	0.36	VFL
$w_{neg}$	0.05	0.24	0.24	0.24	
$w_{pos}$	1.0	0.01	0.06	0.03	DW
$w_{neg}$	0.	0.55	0.31	0.08	

→ 定义锚框的负权重 $w_{pos}$ 与两项相关：

①成为负样本的概率 × ②作为负样本的重要性

## ◆ DW框架

## 负权重函数


①锚框成为负样本的概率：**IoU**是确定锚框为负样本的唯一因素，概率用 $P_{neg}$ 表示。

根据coco指标 $AP^{[0.5:0.95]}$ 定义：

$$P_{neg} = \begin{cases} 1, & \text{if } IoU < 0.5, \\ [0, 1], & \text{if } IoU \in [0.5, 0.95], \\ 0, & \text{if } IoU > 0.95, \end{cases} \quad (5)$$

$$P_{neg} = -k \times IoU^{\gamma_1} + b, \quad \text{if } IoU \in [0.5, 0.95], \quad (6)$$

$\gamma_1$ : 超参数



## ◆ DW框架

## 负权重函数

②锚框作为负样本的重要性:

模型推理阶段: 精度  $Precision \downarrow = \frac{TP}{TP + FP \uparrow}$     召回率  $Recall = \frac{TP}{TP + FN}$

→ 分类分数是确定锚框作为负样本重要性的影响因素, 重要度用  $I_{neg}$  表示。

$\gamma_2$ : 超参数, 表示给予重要负样本的优先权大小

$$I_{neg} = s^{\gamma_2}, \quad (7)$$

→ 负权重  $w_{neg} = p_{neg} \times I_{neg}$ :

$$w_{neg} = \begin{cases} s^{\gamma_2}, & \text{if } IoU < 0.5, \\ (-k \times IoU^{\gamma_1} + b) \times s^{\gamma_2}, & \text{if } IoU \in [0.5, 0.95], \\ 0, & \text{if } IoU > 0.95, \end{cases} \quad (8)$$

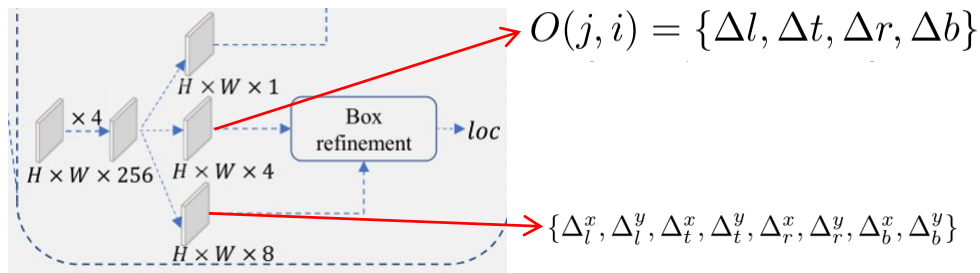
## ◆ DW框架

## 框细化模块

精确的IoU输入将产生更高质量的样本，利于学习更强的特征。

四个橙色点坐标为：

$$\begin{aligned} B_l &= (j + \Delta_l^y, i - \Delta l + \Delta_l^x), B_t = (j - \Delta t + \Delta_t^y, i + \Delta_t^x), \\ B_r &= (j + \Delta_r^y, i + \Delta r + \Delta_r^x), B_b = (j + \Delta b + \Delta_b^y, i + \Delta_b^x), \end{aligned} \quad (9)$$



偏移量特征更新：

$$O'(j, i) = \left\{ \begin{array}{l} \Delta l + \Delta_l^x + O(B_l, 0), \Delta t + \Delta_t^y + O(B_t, 1) \\ \Delta r + \Delta_r^x + O(B_r, 2), \Delta b + \Delta_b^y + O(B_b, 3) \end{array} \right\}$$

